med6m: un adattatore LoRA per Qwen3-8B sul QA medico a scelta multipla

Evidenza su test sigillato per il checkpoint 443 a scala LoRA 0.5

Giovanni Del Papa — ricercatore indipendente, Italia
Progetto *Lo Scienziato Dilettante GDP*

2 novembre 2026
Versione 1.0 — DOI 10.5281/zenodo.23895100
Hugging Face `odelpa/qwen3-8b-med6m` · GitHub `usergdp136/qwen3-8b-med6m`

Sommario

Rilasciamo un adattatore LoRA (rango 64) per `unsloth/Qwen3-8B-unsloth-bnb-4bit`, addestrato con QLoRA su un mix medico di sei mesi (MedMCQA-train, MedQA-train, Wikipedia medica italiana e inglese) con il 22% di replay generale. Su un test *sigillato e a uso singolo* di 3 766 item medici a scelta multipla (MedMCQA, MedQA, sei sottodomini medici di MMLU, PubMedQA) l'adattatore a scala LoRA $s = 0.5$ migliora l'accuratezza rispetto al modello base di +2.34 punti percentuali (pp), IC 95% bootstrap appaiato $[+1.14, +3.53]$, McNemar esatto $p = 1.4 \times 10^{-4}$ (306 item corretti solo con l'adattatore contro 218 solo con la base). Il guadagno si concentra su MedMCQA (+2.89 pp) e PubMedQA (+2.78 pp); MedQA e MMLU-med sono positivi ma con IC che includono lo zero; la guardia generale italiana (ARC-it) non mostra regressioni (+0.74 pp, IC $[-1.29, +2.76]$). Limiti importanti: l'artefatto valutato è il checkpoint 443, non il finale 886; la valutazione usa la log-probabilità della lettera di risposta, non la generazione libera; non si afferma alcuna validità clinica.

1 Metodo

Modello e adattatore. Base: Qwen3-8B (Apache-2.0), caricato a 4 bit NF4 (bitsandbytes). L'adattatore è una LoRA su tutte le proiezioni di attenzione e MLP (`q,k,v,o,gate,up,down`), rango $r = 64$, $\alpha = 64$, senza dropout. Per un peso congelato W_0 il peso adattato è

$$W \;=\; W_0 \;+\; s\,\frac{\alpha}{r}\,BA, \qquad A \in \mathbb{R}^{r \times d_{\text{in}}},\; B \in \mathbb{R}^{d_{\text{out}} \times r}, \tag{1}$$

dove s è la scala LoRA scelta in inferenza (qui $s = 0.5$, $\alpha/r = 1$): l'aggiornamento appreso viene applicato a metà intensità.

Addestramento. Due stadi QLoRA consecutivi su una Tesla T4: lo stadio `S1_v2` (885 passi, lr 5×10^{-5}, seed 3407) sulle sole quattro fonti mediche; lo stadio `S1_v2r` (886 passi pianificati, lr 1.3×10^{-5}, warm-up 25, seed 3408, accumulo gradienti 16, lunghezza massima 2048), inizializzato dall'ultimo adattatore dello stadio 1 e con il 22% di replay (OASST2, Aya, Dolly, Wikipedia italiana, FineWeb-Edu, FineWeb-2-it) per limitare l'oblio. **L'artefatto pubblicato è il checkpoint 443 dello stadio `S1_v2r`** (50% dello stadio). Per il secondo stadio erano pianificati circa 29.5 M di token target efficaci (medico 78%, replay 22%).

2 Protocollo di valutazione

Ogni item è valutato con la log-probabilità della lettera di risposta. Con il chat template (thinking disattivato) e il prompt troncato a 2048 token, la predizione è

$$\hat{y} \;=\; \arg\max_{\ell \in \mathcal{L}} \; z_\ell, \tag{2}$$

dove z_ℓ è il logit del token successivo per la lettera ℓ (con e senza spazio iniziale) e $\mathcal{L}$ l'insieme delle lettere delle opzioni. La generazione libera *non* è valutata. Benchmark: MedMCQA (validation), MedQA-USMLE-4-options (test), sei sottodomini medici di MMLU, PubMedQA (`pqa_labeled`, solo domanda, senza contesto) e ARC-Italian (challenge) come guardia generale. La divisione dev/test è deterministica: SHA-1 di `"split|"+ID`, parità del digest. I dati di training sono stati decontaminati rispetto a dev e test con corrispondenza di 10-grammi. Il test sigillato è stato eseguito *una sola volta* (marcatore `TEST_USED`, 1 novembre 2026) per la base e per il checkpoint 443 a $s \in \{0.5, 0.75\}$; il test è quindi consumato e non può essere riusato per altre selezioni.

3 Statistica

Per l'item i siano $b_i, c_i \in \{0,1\}$ la correttezza di base e adattatore e $d_i = c_i - b_i \in \{-1, 0, 1\}$. L'effetto riportato è

$$\Delta_{\text{pp}} \;=\; \frac{100}{n}\sum_{i=1}^{n} d_i \;=\; \frac{100\,(n_+ - n_-)}{n}, \tag{3}$$

con n_+ (n_-) gli item corretti solo con l'adattatore (solo con la base). Gli intervalli di confidenza sono bootstrap percentile appaiati, implementati come ricampionamento multinomiale dei conteggi,

$$\begin{gathered}(n_-^*, n_0^*, n_+^*) \sim \text{Mult}\big(n;\, \hat{p}\big), \quad \hat{p} = \big(\tfrac{n_-}{n}, \tfrac{n_0}{n}, \tfrac{n_+}{n}\big) \\ \text{IC}_{95} = \big[q_{0.025},\, q_{0.975}\big]\big\{100\,\tfrac{n_+^* - n_-^*}{n}\big\},\end{gathered} \tag{4}$$

con $B = 20\,000$ repliche e seed 20261101. Il test di McNemar esatto bilaterale sulle coppie discordanti ($n_- + n_+ = m$) è

$$p \;=\; \min\Big\{1,\; 2\sum_{k=0}^{\min(n_-,n_+)} \binom{m}{k} 2^{-m}\Big\}. \tag{5}$$

Il pool concatena i quattro benchmark medici e pesa gli *item*, non i benchmark. Non è applicata alcuna correzione per confronti multipli; i valori p per benchmark sono descrittivi.

4 Risultati sul test sigillato

La Tabella 1 riporta il risultato primario (scala 0.5); la Figura 1 mostra le differenze con gli IC per entrambe le scale; la Figura 2 le accuratezze e la Figura 3 guadagni e perdite per item.

Lettura. Il pool medico migliora di +2.34 pp (l'IC esclude lo 0, $p = 1.4 \times 10^{-4}$). Il risultato è guidato da due benchmark: MedMCQA (il mix di training contiene MedMCQA-train, quindi parte del guadagno è adattamento in-distribution al formato d'esame) e PubMedQA. MedQA (+1.55) e MMLU-med (+0.74) hanno IC che includono lo zero: *non* sono miglioramenti confermati. La guardia ARC-it non mostra regressioni sul test sigillato. Le scale 0.5 e 0.75 sono statisticamente indistinguibili sul pool (+2.34 contro +2.44 pp).

Tabella 1: Test sigillato, checkpoint 443, **scala 0.5** contro la base. Accuratezza in %; "+/−" = item corretti solo con l'adattatore / solo con la base. Δ in punti percentuali con IC 95% bootstrap; p McNemar esatto.

Set	n	Base	Adattatore	Δ (pp)	IC 95%	+/−	McNemar p
MedMCQA	2078	57.31	60.20	+2.89	[+1.15, +4.62]	200/140	0.001
MedQA	646	62.85	64.40	+1.55	[−1.55, +4.64]	57/47	0.378
MMLU-med	538	78.25	79.00	+0.74	[−1.67, +3.16]	25/21	0.659
PubMedQA	504	57.94	60.71	+2.78	[+0.60, +5.16]	24/10	0.024
Pool medico (n=3766)	3766	61.34	63.67	+2.34	[+1.14, +3.53]	306/218	<0.001
ARC-it (guardia)	543	88.21	88.95	+0.74	[−1.29, +2.76]	17/13	0.585

Tabella 2: Stesso test, scala 0.75 (riportata per trasparenza; entrambe le scale sono state valutate sullo stesso test consumato).

Set	n	Base	Adattatore	Δ (pp)	IC 95%	+/−	McNemar p
MedMCQA	2078	57.31	60.97	+3.66	[+1.83, +5.49]	230/154	<0.001
MedQA	646	62.85	63.31	+0.46	[−2.63, +3.72]	56/53	0.848
MMLU-med	538	78.25	79.00	+0.74	[−1.86, +3.35]	28/24	0.678
PubMedQA	504	57.94	59.72	+1.79	[−0.40, +4.17]	22/13	0.175
Pool medico (n=3766)	3766	61.34	63.78	+2.44	[+1.17, +3.69]	336/244	<0.001
ARC-it (guardia)	543	88.21	88.77	+0.55	[−1.66, +2.76]	20/17	0.743

5 Checkpoint finale 886 sul dev (non indipendente)

Il checkpoint finale è stato valutato solo sullo split dev, che ha guidato le decisioni di training (gate, scala). Non è quindi una conferma indipendente e non è l'artefatto pubblicato. Sul dev il finale

Tabella 3: Split DEV, checkpoint finale 886 a scala 1.0 contro la base (pool $n = 3779$).

Set	n	Base	Finale	Δ (pp)	IC 95%	+/−
MedMCQA	2105	56.25	59.48	+3.23	[+1.38, +5.08]	238/170
MedQA	627	62.04	65.87	+3.83	[+0.48, +7.18]	70/46
MMLU-med	551	77.13	76.41	−0.73	[−3.63, +2.18]	30/34
PubMedQA	496	53.83	55.44	+1.61	[−0.81, +4.23]	25/17
Pool medico	3779	59.94	62.48	+2.54	[+1.22, +3.84]	363/267
ARC-it (guardia)	589	86.42	84.55	−1.87	[−4.07, +0.34]	18/29

guadagna +2.54 pp sul pool medico ma perde −0.73 pp su MMLU-med e −1.87 pp su ARC-it (IC che includono 0). Il gate storico (due errori standard) lo ammetteva; un criterio più severo (margine −0.5 pp, soglia ARC-it 85.42%) lo respingerebbe. Il criterio del gate è stato rivisto il 31 ottobre 2026 e il checkpoint al 50% è stato rivalutato post hoc. Per questi motivi pubblichiamo il checkpoint 443 (testato sul set sigillato) e *non* il finale.

6 Limiti e rischi

- **Checkpoint contro finale.** L'evidenza riguarda il checkpoint 443; nulla è affermato per l'886.
- **Post-selezione.** Due scale sono state valutate sullo stesso test consumato; la scala 0.5 è stata preferita su criteri dev (variazione ARC-it minore, guadagno PubMedQA maggiore), ma non esiste una scelta preregistrata.

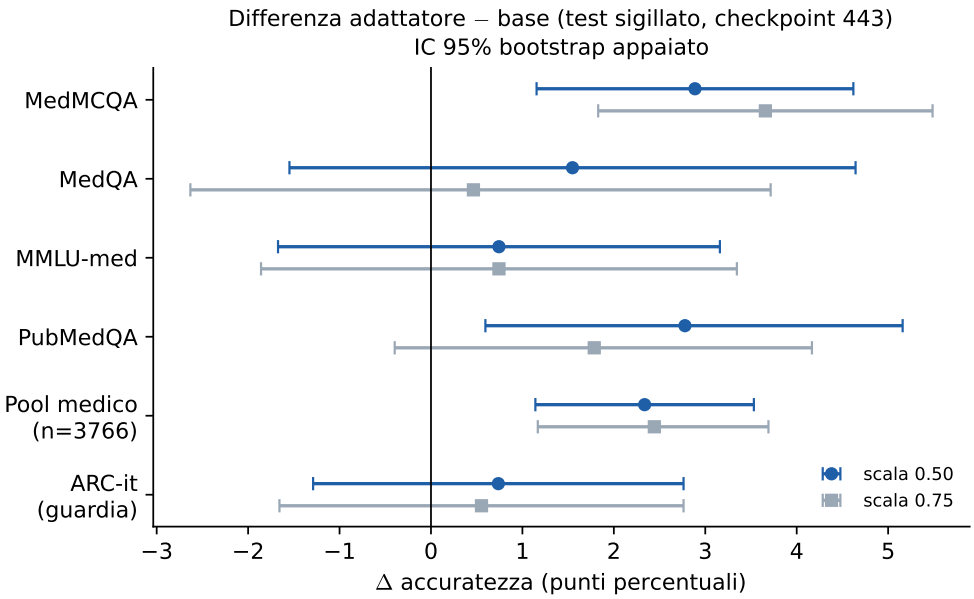


Figura 1: Adattatore meno base, test sigillato. Punti: Δ_{pp} (Eq. 3); barre: IC 95% (Eq. 4).

- **Nessuna correzione per molteplicità**; gli IC per benchmark sono descrittivi. MedQA e MMLU-med non sono significativi.
- **Tipo di compito.** Solo log-probabilità della lettera a scelta multipla; nessuna risposta libera, nessuna valutazione di sicurezza, nessuna validazione clinica. *Non usare per consigli medici.*
- **Controlli di capacità generale in sospeso:** GSM8K e IFEval sul checkpoint 443 *non* sono ancora stati eseguiti; è riportata solo la guardia ARC italiana.
- **Provenienza.** MedMCQA-train è dichiarato Apache-2.0 ma la provenienza delle domande d'esame non è verificata in modo indipendente; le revisioni di modello/dataset non erano fissate al momento dell'addestramento (riportiamo le revisioni in cache sulla macchina di training, Appendice A).
- **Audit di rete.** Una revisione statica del codice di training/valutazione non ha trovato endpoint diversi da Hugging Face e ha `report_to='none'`; un audit dinamico (traffico) non è stato eseguito retroattivamente (Appendice B).

7 Licenze e attribuzione

Modello base: Qwen3-8B, Apache-2.0 (© Qwen Team / Alibaba Cloud; ripacchettamento a 4 bit di Unsloth). Fonti di training e licenze: MedMCQA-train (Apache-2.0, dichiarata), MedQA-train (MIT, split train di `openlifescienceai/medqa`), Wikipedia IT/EN (CC BY-SA 3.0 / GFDL), Dolly-15k (CC BY-SA 3.0), OASST2 e Aya (Apache-2.0), FineWeb-Edu e FineWeb-2 (ODC-By 1.0). Tutte permettono l'uso commerciale; nessuna è non commerciale. Poiché diverse fonti sono share-alike, adattatore, articolo e figure sono rilasciati con licenza **CC BY-SA 4.0** e il codice con Apache-2.0; l'attribuzione è in `ATTRIBUTION.md`. Se la clausola share-alike si estenda giuridicamente ai pesi del modello è questione non risolta; la applichiamo in via cautelativa.

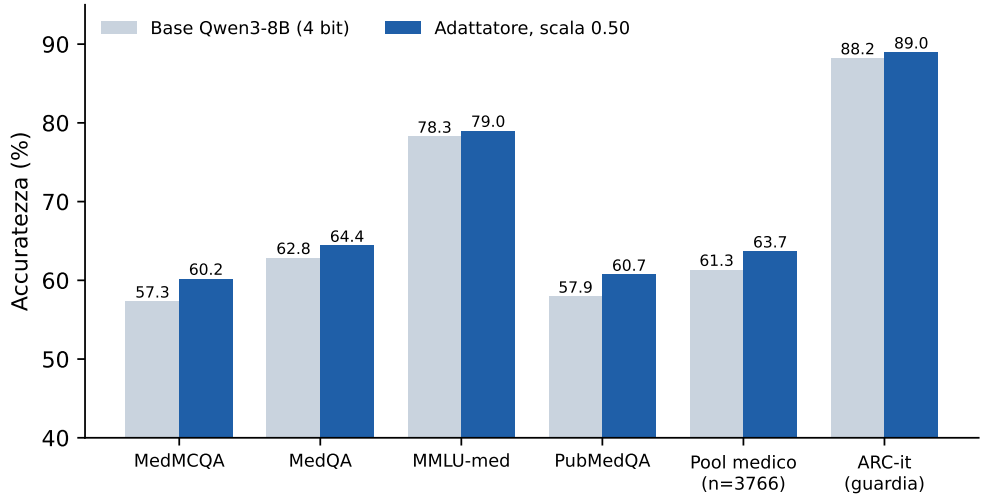


Figura 2: Accuratezza di base e adattatore (scala 0.5).

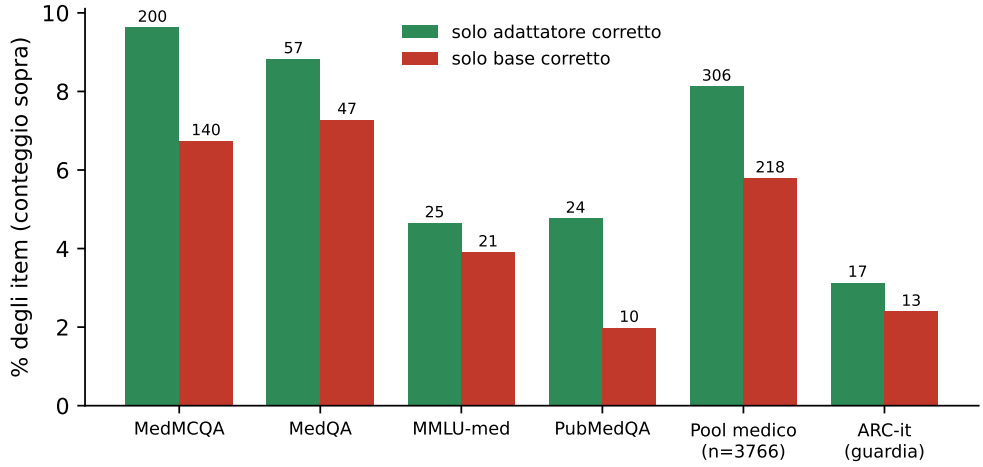


Figura 3: Item corretti solo con l'adattatore (n_+) contro solo con la base (n_-).

8 Riproducibilità

`code/recompute.py` ricalcola ogni numero delle tabelle dai conteggi appaiati (CPU, NumPy, senza rete); `code/make_figures.py` rigenera le figure. L'audit assistito da Codex e il nostro ricalcolo concordano alla seconda cifra decimale (pool +2.3367, IC $[1.1418, 3.5316]$). Gli script di training e valutazione sono forniti per ispezione; richiedono l'ambiente originale (Unsloth 2026.10.7, Transformers 5.17.0, PEFT 0.21.2, TRL 1.15.0, bitsandbytes 0.50.2, PyTorch 2.11.0+cu128).

A Artefatti fissati

B Nota sull'audit di rete

Ambito: il codice med6m (`build_s1v2r.py`, `train_stage_r.py`, `eval_mc.py`, `s0_data.py`, `s0b_data.py`). Esito: l'accesso di rete è limitato ai download di dataset/hub Hugging Face per la preparazione dei dati; `report_to='none'` (nessun W&B o altro tracker); training e scoring leggono file JSONL locali. `pmc.py` (Europe PMC S3) appartiene agli helper di preparazione dati

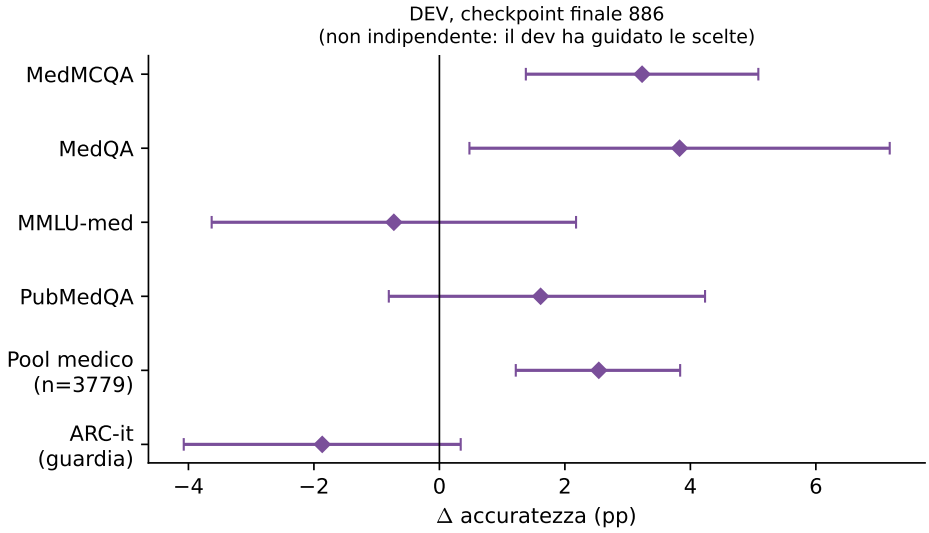


Figura 4: Differenze sul dev per il checkpoint finale 886.

Artefatto	SHA-256 / revisione
`adapter_model.safetensors`	`0dfdebe51f325a0d0e1cc5851193a03c4d6aef898ba3b3a595145ab508c4a5bf`
`adapter_config.json`	`dcabc2e1d6661d1ad5a18f475a7fd08c875e8cba8664ffbea95bff32d0ce6943`
`tokenizer.json`	`476870a1f2fb6f6a2759a6ede2383bf9d5d738f17844563b65c91965b722ae09`
Base `unsloth/Qwen3-8B-unsloth-bnb-4bit`	revision `62efd7f9d748e394734a7adae2adf96e13a2abc8` (in cache dal 24 ott 2026)
`openlifescienceai/medmcqa`	`91c6572c454088bf71b679ad90aa8dffcd0d5868`
`GBaker/MedQA-USMLE-4-options`	`0fb93dd23a7339b6dcd27e241cb9b5eca62d4d18`
`cais/mmlu`	`c30699e8356da336a370243923dbaf21066bb9fe`
`qiaojin/PubMedQA`	`9001f2853fb87cab8d220904e0de81ac6973b318`
`sapienzanlp/arc_italian`	`1860d09fba59b9b2576335ab472346f63c1becc8`
`wikimedia/wikipedia`	`b04c8d1ceb2f5cd4588862100d08de323dccfbaa`

e non fa parte di training/valutazione. Non verificato: nei launcher non sono stati trovati flag d'ambiente (`HF_HUB_OFFLINE`, `UNSLOTH_DISABLE_STATISTICS`), quindi la telemetria delle librerie non può essere esclusa; si raccomanda una riesecuzione offline pulita con cattura del traffico.

Riferimenti bibliografici

[1] T. Dettmers et al., *QLoRA: Efficient Finetuning of Quantized LLMs*, 2023. https://arxiv.org/abs/2305.14314

[2] E. Hu et al., *LoRA: Low-Rank Adaptation of Large Language Models*, 2021. https://arxiv.org/abs/2106.09685

[3] Qwen Team, *Qwen3 Technical Report*, 2025. https://arxiv.org/abs/2505.09388

[4] A. Pal et al., *MedMCQA*, CHIL 2022. https://arxiv.org/abs/2203.14371

[5] D. Jin et al., *What disease does this patient have? (MedQA)*, 2020. https://arxiv.org/abs/2009.13081

[6] Q. Jin et al., *PubMedQA*, EMNLP 2019. https://arxiv.org/abs/1909.06146

[7] D. Hendrycks et al., *Measuring Massive Multitask Language Understanding*, ICLR 2021. https://arxiv.org/abs/2009.03300